

Contents

- 1 论文总结: Training Language Models to Follow Instructions with Human Feedback 2
 - 1.1 0. 术语对照 (align 词族共享词根, 勿拆) 2
 - 1.2 1. 问题设定 3
 - 1.3 2. 方法: RLHF 三步 3
 - 1.4 3. 数据与标注 5
 - 1.5 4. 主要结果 5
 - 1.6 5. 讨论与局限 6
 - 1.7 6. 关键超参数速查 7
 - 1.8 7. 为什么这篇论文重要 7

1 论文总结: Training Language Models to Follow Instructions with Human Feedback

- 作者: Long Ouyang, Jeff Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, ... John Schulman, Jan Leike, Ryan Lowe (OpenAI Alignment 团队)
- arXiv: 2203.02155v1 [cs.CL], 2022 年 3 月 4 日
- 一句话: 把 GPT-3 用”人类示范 + 人类偏好排序 + PPO”做三阶段微调, 得到 InstructGPT; 1.3B 的 InstructGPT 在人类评测中已优于 175B 的 GPT-3。

1.1 0. 术语对照 (align 词族共享词根, 勿拆)

原文	中译	说明
alignment / to align (with) misaligned	对齐 未对齐 (的)	核心术语; 必带参照对象 即 aligned 的否定式, 同词根。 不要译成”错位” “失配”等 与”对齐”看不出关系的词, 否则 alignment tax、aligning to whom 两处推理会断
not aligned with their users alignment tax	未与其用户对齐 对齐税	摘要原句 为消除”未对齐”这一缺陷所付的能力代价
Who are we aligning to?	我们在对齐谁?	§ 5.2; 成立的前提正是 align 必有参照对象
helpful / honest / harmless honesty vs. truthfulness	有帮助 / 诚实 / 无害 诚实 (关乎意图与信念) vs. 真实性 (关乎陈述是否为真)	Askell et al. (2021) 的三元组 论文刻意区分: 前者测不了, 故降级为后者。中文不可混用
intent / intention	意图	对齐的目标是”按用户意图行事”, 含 explicit (遵循指令) 与 implicit (真实、不带偏见、无毒)

原文	中译	说明
preferences / values	偏好 / 价值观	§ 5.4 引 Gabriel (2020): instructions、intentions、revealed preferences、ideal preferences、interests、values 六者有微妙差别，本文为简化只对齐到”推断出的用户意图”
steerability / controllability	可引导性 / 可控性	§ 5.4 指出 RLHF 可与该文献线结合
hallucination	幻觉	本文特指闭域任务中编造输入里不存在的信息

1.2 1. 问题设定

预训练目标（预测网页下一个 token）不同于我们真正想要的目标（“有帮助、安全地遵循用户指令”）。论文用一个词给这个缺陷命名：语言建模目标是**未对齐的（misaligned）**；摘要里的说法是这些模型”**未与其用户对齐**（not aligned with their users）“。把模型做大并不会自动修正这一点：大模型照样会编造事实、输出有毒或有偏内容、无视用户指令。

于是全文的贡献就被定义为这一缺陷的消除：**对齐（aligning）**语言模型，即训练它按用户意图行事（Leike et al., 2018）。注意 align 天生要带一个参照对象（align with whom），这是 § 5.2 追问”我们在对齐谁”的语义前提。

对齐的操作性定义沿用 Askell et al. (2021) 的 **helpful / honest / harmless**（有帮助 / 诚实 / 无害）：- helpful → 用**标注员偏好评分**度量（主指标）；- honest → 作者明确做了一次**术语降级**：诚实（honesty）要求比较模型输出与它的”信念”，而模型是黑箱、无法推断其信念，因此放弃测诚实，改测**真实性（truthfulness）**——只问模型关于世界的陈述是否为真。两个代理指标：闭域任务的幻觉率 + TruthfulQA。作者自己承认这”只捕捉到真实性的一小部分”；- harmless → 同样用代理指标：是否适合客服场景、是否贬损受保护群体、是否含色情/暴力内容，以及 RealToxicityPrompts、CrowS-Pairs、Winogender 等基准。项目早期曾让标注员直接判断”是否潜在有害”，后因需过度猜测输出的实际使用语境而放弃。

1.3 2. 方法：RLHF 三步

阶段	数据	做法
Step 1 · SFT	13k 提示（标注员示范）	在人类示范上监督微调 GPT-3。训练 16 epoch、cosine 衰减、residual dropout 0.2；验证 loss 在 1 epoch 后就过拟合，但继续训练反而提升 RM 分数与人类偏好，故按 RM 分数选 checkpoint
Step 2 · RM	33k 提示（人类排序）	从 SFT 模型去掉最后的 unembedding 层，输出标量奖励。只用 6B RM（175B RM 训练不稳、算力开销大）。给标注员一次看 K=4~9 个回复排序，得到 C(K,2) 个比较对
Step 3 · PPO	31k 提示（无人人类标签）	以 RM 为奖励、用 PPO 微调 SFT 策略，bandit 环境（一个 prompt → 一次回复 → 结束）。逐 token 加 KL 惩罚 （相对 SFT, $\beta=0.02$ ）防止过度优化 RM；value function 由 RM 初始化

RM 损失（成对 Bradley-Terry 形式）：

$$\text{loss}(\theta) = -\frac{1}{\binom{K}{2}} \mathbb{E}_{(x, y_w, y_l) \sim D} [\log \sigma(r_\theta(x, y_w) - r_\theta(x, y_l))]$$

关键工程细节：把同一 prompt 的全部 C(K,2) 个比较放进**同一个 batch 元素**。若打散成独立样本，每个 completion 会被用于 K-1 次梯度更新，一个 epoch 就过拟合；合并后既只需每个 completion 一次前向（而非 C(K,2) 次），验证准确率与 log loss 也显著更好。

PPO 目标（含预训练混合项）：

$$\text{objective}(\phi) = \mathbb{E}_{(x, y) \sim D_{\pi_{\phi}^{RL}}} \left[r_\theta(x, y) - \beta \log \frac{\pi_{\phi}^{RL}(y|x)}{\pi_{\phi}^{SFT}(y|x)} \right] + \gamma \mathbb{E}_{x \sim D_{\text{pretrain}}} [\log \pi_{\phi}^{RL}(x)]$$

$\gamma=0$ 即 “PPO”； $\gamma=27.8$ 即 “**PPO-ptx**”，论文中所说的 InstructGPT 默认指 PPO-ptx。Step 2 与 Step 3 可迭代循环。

1.4 3. 数据与标注

- 提示主要来自 OpenAI API Playground 上早期 InstructGPT 模型收到的真实用户请求（不含生产环境数据），外加冷启动阶段由标注员自写的 plain / few-shot / user-based 三类提示。按 user ID 划分 train/valid/test 并过滤 PII，每个用户最多 200 条。
- 用例分布以生成式为主：Generation 45.6%、Open QA 12.4%、Brainstorming 11.2%、Chat 8.4%、Rewrite 6.6%、Summarization 4.2%，分类与 QA 合计仅约 18%。数据 96% 以上为英文。
- 约 40 名承包标注员（Upwork / Scale AI），经筛选测试挑选，看重对不同人群偏好的敏感度与识别有害输出的能力。标注员间一致率 $72.6 \pm 1.5\%$ （留出标注员 $77.3 \pm 1.3\%$ ），与 Stiennon et al. (2020) 中研究者之间的 $73 \pm 4\%$ 相当。
- 训练时优先 helpfulness，最终评测时优先 truthfulness 与 harmlessness。
- 数据规模（Table 6，提示条数）：SFT train 11,295(labeler)+1,430(customer)；RM train 6,623+26,584；PPO train 31,144。

1.5 4. 主要结果

- ① 人类偏好大幅提升。以 175B SFT 为基线计算胜率：175B InstructGPT 对 175B GPT-3 的胜率 $85 \pm 3\%$ ，对 few-shot GPT-3 为 $71 \pm 4\%$ ；**1.3B PPO-ptx 的输出即优于 175B GPT-3**（参数少 100 倍以上，架构相同，差别只在人类数据微调）。细粒度元数据上 InstructGPT 也更少答错任务、更常遵守显式约束（如“两段以内”）、更适合客服语境、闭域任务幻觉更少。
- ② 真实性改善。TruthfulQA 上 InstructGPT 给出“真实且有信息量”回答的频率约为 GPT-3 的两倍，在非对抗性子集上同样成立；这是默认行为，无需专门提示。闭域任务幻觉率 **21% vs GPT-3 的 41%**。给“不确定就回答 I have no comment”的 Instruction+QA 提示时，PPO 模型倾向选择“真实但无信息”而非自信编造。
- ③ 毒性小幅改善，偏见没有。在“respectful prompt”下 InstructGPT 的毒性输出比 GPT-3 少约 25%（Perspective API 与人工评测一致）；去掉该提示后优势消失；被**明确要求输出有毒内容时 InstructGPT 反而比 GPT-3 更毒**。Winogender / CrowS-Pairs 上未优于 GPT-3，被要求“respectful”时熵反而下降（偏见更强），模式不清晰——指令化模型只是对自己的输出更确定。
- ④ 对齐税可以缓解。默认 PPO 在 SQuADv2、DROP、HellaSwag、WMT15 fr→en 上相对 GPT-3 退化（即 **alignment tax**）。混入预训练梯度（PPO-ptx）能在几乎不损失偏好分数的前提下修复大部分退化，HellaSwag 甚至超过 GPT-3；DROP、SQuADv2 与翻译仍有残留。消融显示： $\gamma \geq 20$ 即可在 1.3B 上恢复， $\gamma=27.8$ 从 1.3B 到 175B 通用；而单纯把 KL 系数 β 提高 100 倍（到 2.0）**无法修复退化**，只会让验证奖励大跌——说明修复的关键在于预训练数据分布本身。
- ⑤ 泛化到留出标注员。未参与任何训练数据生产的标注员，其偏好率与训练标注员接近；5 折交叉验证的 RM 对留出组标注员偏好的预测准确率 $69.6 \pm 0.9\%$ ，相比组内 $72.4 \pm 0.4\%$ 只轻微下降——并非单纯过拟合到训练标注员。
- ⑥ 公开 NLP 数据集不代表真实用法。用同一个 175B GPT-3 在 FLAN 与 T0++ 上各微调约 100 万样本

作对照：二者优于原始 GPT-3、与精心提示的 GPT-3 相当，但不如 **SFT 基线**。胜率上 InstructGPT $73.4 \pm 2\%$ ，T0 $26.8 \pm 2\%$ ，FLAN $29.8 \pm 2\%$ ；头对头分别为 $78 \pm 4\%$ 与 $79 \pm 4\%$ 。原因：公开数据集偏向易自动评测的分类/QA，而真实 API 用量 57% 是开放式生成与头脑风暴，且输入多样性有限。

⑦ **分布外泛化**。尽管代码与非英语在微调数据中占极小比例，InstructGPT 仍能较可靠地总结代码、回答代码问题，有时也能遵循其他语言的指令（但常仍用英语作答）。这说明“遵循指令”这一概念本身被泛化了——对齐在几乎没有直接监督信号的任务上部分保留。

⑧ **仍会犯简单错误**。对假前提指令会顺着假设走（“冥想后为什么要吃袜子”）；过度对冲（简单问题也说“没有唯一答案”，作者推测源于标注指南奖励 epistemic humility，被 RM 学到）；指令含多个显式约束时性能下降。作者认为前两类可通过对抗式数据收集大幅缓解。

1.6 5. 讨论与局限

对齐研究的启示 1. **对齐成本相对预训练很低**：175B SFT 约 4.9 petaflops/s-days、175B PPO-ptx 约 60，而 GPT-3 预训练是 3,640——即 PPO-ptx 约为预训练的 **1.6%**，效果却超过把模型放大 100 倍。当前增加对齐投入比训练更大模型更划算（至少对客户自然语言任务分布而言）。2. 对齐在未监督场景（代码、非英语）有泛化迹象，这很重要，因为让人类监督每个任务不可行。3. 低对齐税是技术能否被采纳的关键：高税会激励人们去用“未对齐但更强”的模型。4. 把偏理论/合成环境的对齐研究落到了真实生产系统上，形成经验反馈回路。

“我们在对齐谁？”（§ 5.2，全文最坦诚的一节）模型行为由底座模型、微调数据与对齐方法共同决定，而本文实际对齐的是：① 约 40 名标注员的偏好（多为居住在美国或东南亚的英语使用者，互相之间约 27% 不一致）；② 研究者自身的偏好（标注指南与答疑由作者撰写）；③ OpenAI 客户认为有价值的用途（客户目标可能与其终端用户利益不一致）；④ 而 API 客户来自以 OpenAI 员工为种子的候补名单，并不代表全体受影响人群。作者明确表示不主张这三方是偏好的“正确来源”，并指出**不可能训练出同时对齐所有人偏好的系统**；一条可能路径是训练可按群体偏好条件化的模型。

局限：标注团队小且不具代表性；多数比较只由 1 人标注（成本原因），无法识别分歧区域，而在分歧场景下“对齐到平均偏好”未必可取；模型既不完全对齐也不安全，仍会产生有毒、有偏、编造内容；**最大局限是模型基本会照做用户指令——即使该指令会导致现实危害**（被要求“最大化偏见”时比同规模 GPT-3 更毒）。

开放问题：对抗式数据收集；过滤预训练数据（也包括 pretraining mix 中的有毒内容）；与 WebGPT 等提升真实性的方法结合；**训练模型拒绝有害指令**（作者明确说会在后续迭代中探索——这正是后来 ChatGPT / Constitutional AI 方向）；RLHF 与 control codes、推理期小模型引导等可控性方法结合；除 PPO 外的算法（expert iteration、behavior cloning 子集、约束优化）；比较排序未必是最高效的反馈形式（可让标注员直接编辑回复或写自然语言批评——后来的 critique / RLAIIF 路线）；以及如何设计透明、有代表性、能在多群体间取得共识的对齐流程（引 Gabriel 2020 的“原则式对齐”）。

更广影响：让模型更善于遵循意图，也让它更易被滥用（生成可信的虚假信息、仇恨内容）。对齐技术不是万灵药，只是更大安全生态中的一个工具；高风险领域（医疗诊断、按受保护特征分类、信贷/

就业/住房资格、政治广告、执法）应极其谨慎或干脆不部署。开源难以限制滥用，而只由少数机构掌握则排除了大多数人的访问；API 模式可实施用途限制、滥用监测与限流，代价是透明度下降与权力集中。

1.7 6. 关键超参数速查

项	值
模型规模	1.3B / 6B / 175B（GPT-3 架构）
RM	统一 6B，从在公开 NLP 数据集上微调过的 6B GPT-3 初始化；1 epoch，lr 9e-6，cosine 降至 10%，batch 64 个 prompt（≤2,304 个比较对）；平局丢弃
RM 归一化	加偏置使标注员示范的平均分为 0
RLHF 初始化	预训练 GPT-3 → SFT 2 epoch（混 10% 预训练数据）；peak lr: 1.3B 5e-6 / 6B 1.04e-5 / 175B 2.45e-6
PPO	256k episodes（约 31k 唯一 prompt）；batch 512、minibatch 64（8 个 minibatch，单次内层 epoch）；clip 0.2；采样温度 1；EMA 衰减 0.992；GAE 不折扣；warmup 10 iter
KL 系数 β	0.02
预训练混合系数 γ	27.8（预训练样本数为 RL episode 数的 8 倍）
Value function lr	1.3B/6B 9e-6；175B 5e-6
算力	SFT 175B 4.9 / PPO-ptx 175B 60 / GPT-3 预训练 3,640 petaflops/s-days

1.8 7. 为什么这篇论文重要

- 把 Christiano et al. (2017) 与 Stiennon et al. (2020)（摘要任务）的 RLHF 从单一窄任务推广到开放域指令分布，成为此后 ChatGPT 及几乎所有对话模型后训练流程的模板（SFT → RM → PPO）。
- 提出并量化了 **alignment tax** 概念，并给出可行缓解手段（预训练梯度混合）。
- 明确区分 **instruction tuning on public NLP datasets (FLAN/T0)** 与 **on-distribution 人类偏好数据**，用实验说明后者对真实用法更关键——这一结论直接塑造了后续数据策略。
- 对”对齐谁的偏好”给出了罕见坦率的讨论，成为后续 pluralistic alignment / 多元价值对齐研究的常被引出发点。

- 留下的两个最大缺口，正好预告了接下来两年的主线：**拒绝有害指令**（→ RLHF safety、Constitutional AI）与**比较排序之外更高效的反馈形式**（→ critique、DPO 等免 RL 的偏好优化）。