

V* 论文总结

V*: Guided Visual Search as a Core Mechanism in Multimodal LLMs Penghao Wu (UC San Diego, 实习于 NYU)、Saining Xie (New York University) arXiv:2312.14135v2, 2023-12-26, 共 18 页 (正文 9 页 + 附录 A/B/C)

0. 术语对照表

本篇实际用到的名词，中文只在第一次出现时给，正文里一律用英文原词。

英文	本篇含义
visual search	视觉搜索。在一幅内容繁多的图里找到并定位某个特定对象的过程
MLLM (multimodal LLM)	多模态大语言模型
target	保留英文。问题要用到、但当前看不清的那个对象，也就是搜索的目标
grounding / visual grounding	保留英文。把问题里指称的对象落实到图中的具体位置
localization / localize	定位。特指模型模块输出坐标或 heatmap 这个具体动作（与 grounding 区分：grounding 是任务层面的"对上"，localization 是模块层面的"给出位置"）
VWM (visual working memory)	视觉工作记忆
cue	线索
target-specific cue	关于 target 本身的线索，模型直接看出"那一块像是 target"
contextual cue	上下文线索，靠常识判断"这类 target 通常出现在什么位置"
search cue heatmap	搜索线索热力图
confidence score	置信度分数
priority score	优先级分数
sub-image / patch	子图。V* 把当前图像切开得到的那几块，论文两个词混用
search length	搜索长度。从整图出发到 target 所在子图为止的搜索步数
vision encoder	视觉编码器
projection module	投影模块。把视觉特征映射到 LLM 输入空间的那一层

英文	本篇含义
resampler	保留英文。基于 cross-attention 的投影模块，会减少 token 数 (256 → 32)
REC (referring expression comprehension)	指代表达理解
hallucination	幻觉
fixation	注视点。人眼在搜索时依次落到的位置
grokking	保留英文。论文用它指损失在若干步之后突然掉到 0 的现象
SEAL	本文提出的元架构 (meta-architecture)，摘要里展开为 Show, sEArch, and Tell
V* Bench	本文提出的评测集

1. 这篇论文要解决什么问题


论文的出发点是认知科学里的一个观察：人在复杂场景里找东西不是把整幅画面一次看清，而是**有引导地搜索**。引导来自两个方面，一是 top-down feature guidance（自顶向下的特征引导），按颜色、形状、朝向这类属性把注意力导向符合描述的物体；二是 contextual scene guidance（场景上下文引导），靠“现实场景是有结构的”这一常识——物体一般不会随便乱放——直接把注意力投到可能的区域上，从而加快搜索。

当时的 MLLM 没有这套机制。论文指出的直接原因是它们都依赖一个预训练好、通常还冻住的 vision encoder（例如 CLIP 的图像编码器），而这个编码器的训练分辨率只有 224×224 或 336×336，部署时图像还会被缩到更低的分辨率。于是一张高分辨率、内容拥挤的图里，关键细节在进入 LLM 之前就已经丢了。更麻烦的是第二层问题：模型**不知道自己丢了什么**，既不能指出哪部分视觉信息缺失或不清楚，也没有办法主动去把它取回来。结果就是要么拒答，要么编一个答案出来（也就是 hallucination）。

论文举的例子（Figure 1）是问“杯子里的液体是什么颜色”。图的分辨率是 1920×830，杯子只占很小一块。GPT-4V 直接答了“粉色”，而正确答案是绿色。

作者同时指出，当时的 MLLM 评测集（MME、SEED-Bench、MMBench 这一类）追求的是任务类别覆盖广，题目里的视觉元素本身都比较大、比较显眼，因此不会把上面这个问题暴露出来。

论文的三项贡献对应三样东西：**SEAL** 是一个元架构，让 MLLM 能主动判断缺什么、再去找；**V*** 是 SEAL 里那个 LLM 引导的搜索算法，可以在任意分辨率的图上做有引导的搜索；**V* Bench** 是一个专门考察高分辨率图上细粒度 grounding 能力的评测集。



论文 Figure 1

2. 方法

SEAL 由两个部分组成：一个 VQA LLM 和一个 visual search model，两者不直接对话，而是通过 VWM 这块共享的存储交互。整体实例化见 Figure 3：左半边是 VQA LLM，右半边是 V* 的搜索流程。论文用 LLaVA-7B 同时充当这两处的 MLLM。




Figure 3. An instantiation of the proposed SEAL framework. The left section represents the VQA LLM, which utilizes all the data within the Visual Working Memory to respond to questions. On the right, we illustrate the operational pipeline of the V* visual search algorithm.

论文 Figure 3

2.1 整条流水线（Algorithm 1）

给定图像 I 和问题 T，VQA LLM 先只看整图特征，判断这些信息够不够回答问题。够就直接答，搜索机制不会被触发——这一点论文写得很明确，visual search 不是每次都跑。不够的话，它要输出一个列表，把回答问题所必需、但在整图特征里缺失或不够清楚的 target 一个个列出来。

然后初始化 VWM。VWM 有四个块：<question> 放原始问题文本，<global image> 放整张原图，<searched targets> 放搜索到的 target 裁剪图，<target location> 放这些 target 的坐标。

接着对列表里的每个 target 调用一次 V* 搜索。找到了就从原图上把那块裁下来，连同坐标一起写进 VWM，写入的形式是 "{target} <object patch> at location [x1, y1, x2, y2]"; 找不到就写一句 "{target} not existent in the image"。所有 target 处理完，VQA LLM 再读一遍 VWM 里的全部内容，给出最终回答。

2.2 VQA LLM 与 token 预算

VQA LLM 用 CLIP ViT-L/14 做特征提取，输入缩放并 padding 到 224×224；整图和 target 裁剪图都走这同一个编码器。投影模块准备了两种：linear layer 保留编码器输出的全部视觉 token，resampler 把 token 数压下来 (256 → 32)。

因为 VWM 里可能同时存着整图和若干个 target，token 会很快堆起来，所以论文设计了一个切换规则：VWM 里没有任何 searched target 时，整图走 linear，保留全部 token；有一到两个 target 时，认为模型该把注意力放在这些 target 上，于是 target 走 linear、整图走 resampler；超过两个 target 时，全部走 resampler 压缩，以控制计算开销。

附录 A.3 给出了喂给 LLM 的实际输入序列：

```
<Image>
Additional visual information to focus on:
{Target Object 1's Name} <Object> at location [x1, y1, x2, y2];
{Target Object 2's Name} <Object> at location [x1, y1, x2, y2];
...
Question
```

其中 <Image> 是整图的特征 token，<Object> 是 VWM 里某个 target 的特征 token。

2.3 VQA LLM 的训练数据 (387k)

VQA LLM 要学一件原本的 LLaVA 不会的事：承认自己看不清，并把缺的东西列出来。论文为此构造了三部分数据。

负样本数据 100k，教模型“说不知道 + 列出需要什么”。做法有两种：一是问图里根本不存在的一两个物体；二是问图里确实存在、但 bounding box 小于 20×20 的物体的细节——这种尺寸在 CLIP 编码器下基本看不到。这两种情况的标准答案都是直接说明无法回答，并列全所需的 target。数据基于 COCO2017，问题由 GPT-3.5 生成。

VQA 数据 167k，教模型在 VWM 里有 target 的情况下正确作答，由三块拼成：GQA 70k、物体属性 51k（来自 VAW 数据集）、空间关系 46k（用 COCO2017 生成两个物体相对位置的问题）。GQA 和属性这两块还额外做了一道筛选（附录 A.1）：先用 InstructBLIP 答一遍，只保留它能答对的题；再用图像 inpainting 模型 LaMa 把问题里提到的物体从图上擦掉，重新问一遍，只保留擦掉之后答不对的题。这样筛出来的题，其答案确实依赖那个具体物体，而不是靠语言先验猜出来的。

LLaVA 指令微调数据 120k，用来保住通用的多模态问答和指令跟随能力：LLaVA-80K 原样保留，另外从中抽出与 COCO 类别对应、且该图里有 box 标注的名词短语，把这些物体指定为 target，额外造出 40k。

2.4 visual search model 的结构

先说这个模型要解决的任务和 REC 的区别。REC 是给一句指代表达、在图里定位对应物体，但它面对的图尺寸固定；visual search 必须适配任意分辨率，有时还得把整幅图翻一遍才能找到，所以**效率本身是评价指标的一部分**——不只是找得准，还要找得快。最朴素的做法是把图切成大小一致的小块逐块检测（航拍图和病理全切片分析里常用），但分辨率一高就太慢。

V* 的搜索模型由一个 MLLM 加一个定位模块构成。定位模块里有一个图像 backbone 和两个解码器： D_{tl} (target localization decoder) 和 D_{cl} (search cue localization decoder)。MLLM 的词表里加了一个 $\langle LOC \rangle$ token。给定图像和一段文本表达，文本先被套进固定模板 ("Please locate the [object] in the image.") 再和图像一起喂进 MLLM，MLLM 输出 $\langle LOC \rangle$ ，这个 token 的 embedding v_{loc} 携带了该表达对应的上下文和位置信息。 v_{loc} 经两个各自独立的 MLP 得到 v_{tl} 和 v_{cl} ，再分别和视觉编码器出来的 image token 一起送进 D_{tl} 和 D_{cl} ： D_{tl} 输出 target 坐标和 confidence score， D_{cl} 输出 search cue heatmap。论文说 D_{cl} 的结构类似 SAM 的 mask decoder， D_{tl} 则是两个线性头，一个回归坐标、一个预测 confidence score。




Figure 4. Detailed structure of the *target* localization decoder D_{tl} , and the *search cue* localization decoder D_{cl} .

论文 Figure 4

训练细节在附录 A.3：MLLM 用 LLaVA-7B-v1.1，图像 backbone 用 OWL-ViT-B/16 的 vision encoder； D_{cl} 用分割损失 (binary cross-entropy + DICE loss)， D_{tl} 用类似 DETR 的 set prediction loss、坐标部分用 focal loss；整体训 100K 步、batch 64、学习率 $1e-4$ 。训练时 MLLM 用 LoRA、词嵌入层可训；定位模块的图像编码器和 D_{tl} 里的坐标 MLP 冻结，confidence score 的 MLP 和 D_{cl} 可训。

搜索模型的训练数据分两部分：检测与分割数据（COCO–Stuff、LVIS–PACO、refCOCO(+/g)、refCLEF 既当检测又当分割用，Objects365 v2 和 GoldG 只当检测用），以及 VQA 数据（possible location 问答 + LLaVA–80K）。三者采样比例 15:8:15。

这里的 **possible location 问答** 是 contextual cue 能力的来源，构造方式值得单看（附录 A.2）：从 COCO2017 随机取图，对每张图取 2 个 **不在这张图里、但出现在 CLIP embedding 最相似的 5 张图中的物体**，把这张图的 5 条 caption 和已有物体列表喂给 GPT–3.5，让它用常识回答这些物体最可能出现在哪里，答案要求是“参照图中已有实体的一句十个词以内的短语”（论文 Table 6 给了完整 prompt，示例是 bird → in the sky、flag → on the roof of the building）。也就是说，模型学的是在看不见目标的前提下、靠场景常识说出它该在哪儿。

2.5 V* 搜索算法 (Algorithm 2)

给定当前图像 I_p （第一轮就是整图）和 target 的文本表达 s ：

第一步，直接让搜索模型定位 s ，同时拿到坐标 + confidence score 和 search cue heatmap。confidence 够高就返回坐标，搜索到此结束。

第二步，没定位到就看那张 heatmap。如果 heatmap 的最大值超过阈值 δ ，说明存在明显的 target-specific cue，直接拿它当作指导。如果没超过，就换一个问法问 MLLM：“What is the most likely location of the [target] in the image?”，让它用常识结合图像上下文给出一句 contextual cue（例如“玻璃杯最可能出现在餐桌上”），再把这句话里的名词短语拿去让 D_{cl} 定位，得到 contextual cue 对应的 heatmap。

第三步，把 I_p 递归切成 4 个不重叠、等大的子图。切法按长宽比定：宽大于高的两倍（landscape）竖着切成 4 条，高大于宽的两倍（portrait）横着切成 4 条，其余情况横竖各一刀切成 2×2 ，目的是让每个子图尽量接近方形。然后用上一步的 heatmap（target-specific 的或 contextual 的）给每个子图算 priority score，把（子图，优先级）对放进优先队列，按优先级依次取出处理。




Figure 5. Images are recursively divided into four patches based on their aspect ratio. Landscape images are divided vertically. Portrait images are divided horizontally.

这个过程递归进行，直到 target 被定位，或当前子图尺寸小于预设阈值为止。论文自己在脚注里承认了一个边界情况：简单四等分会把正好卡在子图边界上的 target 切开，必要时可以改用重叠子图或按 heatmap 分布用变尺寸子图——但本文没有这么做。

阈值的具体取值在附录 A.4：confidence 用了两档，高阈值 0.5，整轮搜索都没有任何 target 越过它时，退而取全程 confidence 最高的那个，只要超过低阈值 0.3 就接受（V* Bench 上的评测就是这么做的）。 δ 取 $\max(3.0, 6.0 \times 0.7^l)$ ， l 是当前细分层级——即 $l=0$ 时 6.0、 $l=1$ 时 4.2、 $l \geq 2$ 之后恒为 3.0，越往深处越容易相信 target-specific cue。另外论文说明，当前的搜索过程只找单个 target，不做穷尽式地找全所有实例；但如果在整图上一次就直接定位到多个，会把它们都加进 VWM。




Figure 7. Examples of the LLM-guided visual search process. Each row in each example represents a step in the visual search process and the heatmap of contextual cue or target-specific cue is shown on the right.

论文 Figure 7

2.6 和 A* 的类比

V* 这个名字来自 A*。论文给的对应关系是：子图相当于节点 n ，代价函数 $g(n)$ 对所有节点取同一个正常数，启发函数 $h(n)$ 取 search cue heatmap 算出的 priority score 的相反数。区别在目标：A* 求的是起点到终点的最小代价路径，V* 只关心定位到目标所需的总步数最少。

论文同时把这套主动搜索归到 System II（慢思考）那一类认知过程——复杂任务需要动态分配计算量——并说它可以看作 CoT（chain-of-thought）在视觉侧的对应物。

3. 实验与主要结果

3.1 V* Bench 是怎么建的

基于 SA-1B 数据集里的 191 张高分辨率图，平均分辨率 2246×1582。两个子任务：attribute recognition 115 题，问某个物体的某类属性（颜色、材质等）；spatial relationship reasoning 76 题，问两个物体的相对空间关系。图和题都由人工挑选和撰写，标准是不做准确的 grounding 就很难猜对。

为了能和开源模型定量比较，每题都配了选项：开放式问题 4 个选项，二选一问题 2 个选项，选项经人工复核以排除歧义。

附录 B 里还额外收了两个探索性子集，也归进 V* Bench: OCR 30 题，需要识别图中物体上的文字或数字；GPT-4V-hard 17 题，是专门挑出来的"GPT-4V 答错而本文模型答对"的样本。

3.2 主结果 (Table 1)

单位 %，Overall 是 191 题上的总体准确率（按 115:76 加权，与两个子任务的数字自洽）。

系统	Attribute	Spatial	Overall
Human	98.26	100.00	98.95
Random Guess	26.73	50.00	35.99
BLIP2	26.95	53.94	37.69
MiniGPT-4	30.43	50.00	38.22
LLaVA	23.47	53.94	35.59
InstructBLIP	25.21	47.36	34.02
Otter	26.95	56.57	38.74
LLaVA-1.5	43.47	56.57	48.68
MM-React	34.78	51.31	41.36
VisualChatGPT	30.43	48.68	37.69
Visprog	31.30	56.57	41.36
Bard	31.30	46.05	37.17
Gemini Pro	40.86	59.21	48.16
GPT-4V	51.30	60.52	54.97
SEAL (本文)	74.78	76.31	75.39

要点：大部分 MLLM 贴着随机猜的水平；LLaVA-1.5 在 attribute 上比 LLaVA 明显好 (23.47 → 43.47, Overall 35.59 → 48.68)，论文把这部分归因于换了训练分辨率更高的 vision encoder (CLIP-ViT-L-336px)，但离本文的搜索策略仍有相当距离；SEAL 只用 Vicuna-7B 就超过了 GPT-4V 二十个百分点，而人类接近满分，说明 MLLM 还有很大提升空间。代价方面，V* 搜索在单张 A100 上平均每个 target 耗时 6.0 秒。

评测协议对两类系统不同：开源端到端模型用 likelihood 方式（取 log-likelihood 最高的选项），LLM-tool-using 系统和商用聊天机器人则直接要求它们输出选项。Bard 和 GPT-4V 走网页端（访问日期 2023-10-31），Gemini Pro 走 API（2023-12-16）。

3.3 消融：搜索机制是不是必需的（Table 2）

四组实验都用 Vicuna-7B，都在同一份训练数据上训。

ID	VWM	Search	Attribute	Spatial	Overall
1	✗	N/A	38.26	55.26	45.02
2	✓	直接查检测模型（GroundingDINO）	62.60	61.84	62.30
3	✓	直接查检测模型（OWL-ViT）	60.86	65.78	62.82
4	✓	V*-Search	74.78	76.31	75.39

结论分两层：训练数据里已经包含属性和空间关系的题，但没有搜索机制的模型（ID 1）依然只有 45.02；把搜索换成现成的开放词表检测器（ID 2/3）能补回一大截，但仍明显不如 V*，而且论文指出这类检测器用在超高分辨率图上本身就有工程困难。

3.4 搜索效率（Table 3、Table 4）

先在 V* Bench 上比。论文记下了 V* Bench 里全部 245 个 target 位置，用 **search length** 衡量效率，只统计搜索后成功定位的样本。两个基线：Random 随机挑子图，Sequential 按倒序光栅扫描顺序挑；每个都分 DFS 和 BFS 两种。

策略	Search Length ↓
Random-DFS	8.94
Random-BFS	7.18
Sequential-DFS	11.39
Sequential-BFS	6.62
LLM-guided visual search	4.65
w/o target-specific cue	5.22
w/o contextual cue	5.36

两种 cue 各去掉一个都会变慢，说明两者都在起作用。

再和人类注视行为比。数据用 COCO-Search18 的验证集，只取确实需要搜索才能定位的样本。做法是把人的 ground-truth fixation 序列转成二维 heatmap——在每个 fixation 点上叠一个高斯分布，并按点在序列中的次序给第 i 个点乘上权重 γ^i ($0<\gamma<1$) ——再拿这张 heatmap 当作引导去跑同一套搜索流程。

策略	Search Length ↓
Random-DFS	9.97
Random-BFS	4.90
Sequential-DFS	9.82
Sequential-BFS	4.20
Human Fixation ($\gamma=0.9$)	2.52
Human Fixation ($\gamma=0.8$)	2.70
LLM-guided visual search	2.80

V* 达到了和人类注视相近的效率。注意这两张表的数字不能横着比——数据集不同，COCO-Search18 的图小得多，所以连基线都快很多。Figure 6 给了定性对比：人倾向于盯住中心区域或显著物体，而本文模型关注的是更大的上下文区域。

3.5 通用多模态能力有没有受损 (Table 5)

LLaVA* 指的是用本文同一份 VQA 训练数据训出来、但没有 VWM 和搜索机制的 LLaVA，也就是 Table 2 的 ID 1。

	V* Bench	MME	POPE	MMBench	SEED-Bench(img)	MM-Vet	LLaVA_W
LLaVA* (7B)	45.0	1051.2	76.5	34.4	41.8	30.4	62.6
SEAL (7B)	75.3 (+30.30)	1128.9 (+77.70)	82.4 (+5.85)	33.1 (-1.36)	41.7 (-0.17)	27.7 (-2.70)	59.1 (-3.50)

综合评测 MME 提升，幻觉评测 POPE 也提升；MMBench 和 SEED-Bench 基本持平；MM-Vet 和 LLaVA-Bench(W) 略降，论文给了两个解释：这两个集规模小且用 GPT-4 打分，本身波动和偏差较大；另外它们有些题会触发对图表类目标的搜索，而搜索模型是在常见物体上训的，容易找不到。

附录 C 还记了一个现象：单独用 46K 空间关系数据训 VQA LLM 时，损失不是逐渐下降，而是在若干优化步之后突然掉到 0（论文称之为 grokking），说明模型是在某一刻才学会比较数值坐标来判断相对位置的。论文由此建议，如果要把这类数据混进更大规模的指令微调数据里，应该提高它的比例，否则可能凑不够触发这一跳变所需的优化步数。

4. 局限与待核实之处

作者自己承认的：当前的搜索模型只针对自然图像和常见物体；要扩展到文档、图表、长视频或开放世界环境，需要额外训练和新的算法设计。论文还提了一个改进方向：引入基于卷积的模型来更高效地处理任意分辨率的图像。

评测设置上值得注意的几点。 第一，Table 1 里 SEAL 是在专门构造的属性 + 空间关系数据上训过的，其他模型都没有在这类数据上专门训练过，这个比较不是训练数据对齐的；真正对齐的是 Table 2 的 ID 1 和 Table 5 的 LLaVA* (45.0 → 75.3)。论文安排了这两组实验，但正文没有把这层区别讲明。第二，开源模型走 likelihood、商用系统走直接选选项，两套协议的结果放在同一张表里并不严格可比。第三，V* Bench 只有 191 题，1 题≈0.52 个百分点，几个点的差距对应的只是一两道题。第四，Human 那一行的 98.26/100.00 没有说明由几个人、怎么测的。

GPT-4V-hard 子集的构造方式有选择偏差。 这 17 题是按"GPT-4V 错、本文模型对"筛出来的，在它上面比较两者本身没有意义。论文把它归为探索性子集、也写明了构造方式，算是透明，但结果 (Figure 10) 仍然不能当作能力对比来读。另外这两个子集被"加进 V* Bench"，而 Table 1 的 Overall 只覆盖那 191 题，别人复用这个 benchmark 时容易搞混。

正文和附录对投影模块的描述互相矛盾。 §3.1.1 说 VWM 里有一到两个 target 时，target 走 linear、整图走 resampler；附录 A.3 说训练时只有一个 target 才让 target 走 linear，否则是整图走 linear、target 走 resampler。两处的切换条件和谁走哪条路都对不上，论文没有说明这是推理与训练的有意差异还是笔误。

记号不统一。 Figure 3 里两个定位解码器标成 M_{tl} 和 M_{cl} ，正文和 Figure 4 里却是 D_{tl} 和 D_{cl} ；VWM 的第四个块在正文里写作 $\langle \text{target location} \rangle$ ，在 Figure 1 和 Figure 3 里写作 $\langle \text{target locations} \rangle$ 。另外 SEAL 的展开在摘要里是 "Show, sEArch, and TeLL"，在 §3 开头是 "Show, Search and Tell"。

伪代码和正文没有完全对齐。 Algorithm 1 第 8 行调用 $\text{Visual Search}(q, s, \delta)$ ，但整个 $\text{SEALVQA}(I, T, \delta)$ 里没有 s 这个变量，按上下文应该是循环变量 target 。Algorithm 2 也没有体现正文说的"子图尺寸小于阈值就停"这一终止条件。

和 A* 的类比偏松。 论文说 $g(n)$ 对所有节点取同一正常数、 $h(n)$ 取 priority score 的相反数，但 Algorithm 2 里优先队列只按 heatmap 算出的优先级排序，没有任何随深度累积的代价项。这种形式更接近贪心最佳优先搜索 (greedy best-first)，而不是 $f = g + h$ 意义上的 A*。

几个数字我没法从论文里核出来。 一是 §5.3 说"记录了 V* Bench 里全部 245 个 target 位置"：115 道属性题各 1 个 target、76 道空间题各 2 个 target，应该是 267 个，论文没有解释这 22 个的差额从哪来。二是 Table 5 里 POPE 的 76.5 → 82.4 标成 +5.85、MMBench 的 34.4 → 33.1 标成 -1.36、SEED 的 41.8 → 41.7 标成 -0.17，差值是按更高精度的原始数算的，和表里显示的一位小数对不上。三是附录 A.3 说 D_{tl} 里的坐标 MLP 在训练中冻结，而定位模块的图像 backbone 用的是 OWL-ViT 的 vision encoder——坐标头大概率是直接沿用 OWL-ViT 的预训练权重，但论文没有明说。

Table 3 的比较口径有一处松动。 论文说 search length 只统计"搜索后能成功定位"的样本，但不同策略成功定位的样本集合不一定相同，如果各行统计的是各自的成功子集，平均搜索长度就不是在同一批样本上比的。论文没有说明这一点是怎么处理的。

参考文献 [53] 和 [54] 是同一篇。 两条都是 Chenfei Wu 等人的 Visual ChatGPT，但 Table 1 里 MM-React 引的是 [53]、VisualChatGPT 引的是 [54]，MM-React 的引用应该是错的。([32] 和 [33] 也是重复条目，同为 Mao et al.，这一条影响不大。)