

ViT 论文总结

An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale Dosovitskiy et al., Google Research (Brain Team), ICLR 2021, arXiv:2010.11929v2

0. 一句话结论

把图像切成固定大小的图块(patch)、当成词元(token)序列，喂进一个几乎没有任何改动**的标准 Transformer 编码器**，只要预训练数据规模够大（1400 万~3 亿张图），就能在图像分类上追平甚至超过当时最强的卷积网络，而且预训练算力只要对方的 1/4 到 1/5。

1. 背景：这篇论文要挑战什么

2020 年时的分工是：NLP 已经全面转向 Transformer（预训练大语料 + 下游微调），而计算机视觉仍然由**卷积网络(CNN)**主导。

理解这篇论文只需要知道 CNN 的一个特点：它的每一层都内建了两条关于图像的先验假设，论文称之为**归纳偏置(inductive bias)**：

- **局部性(locality)**：一个输出只看输入里一小块相邻区域，默认"相邻像素才相关"。
- **平移等变性(translation equivariance)**：物体在图里平移，输出的特征图也跟着平移，识别结果不变。

这两条假设是人工塞进架构里的、关于"图像长什么样"的知识。它让 CNN 在数据不多时也学得很好。

在此之前，把注意力用到视觉上的尝试有两类：一是 CNN + 注意力混着用；二是用特殊的注意力模式（只在局部邻域算、只沿某个坐标轴算、稀疏注意力）整个替换卷积——后者理论上省算力，但需要复杂的工程实现，在加速器上跑不快，因此大规模图像识别仍是 CNN 的天下。

本文的主张：**这套对 CNN 的依赖不是必需的**。不加视觉专用的归纳偏置，只靠数据规模，标准 Transformer 就够了。

2. 方法：ViT 是怎么搭的




Figure 1: Model overview. We split an image into fixed-size patches, linearly embed each of them, add position embeddings, and feed the resulting sequence of vectors to a standard Transformer encoder. In order to perform classification, we use the standard approach of adding an extra learnable “classification token” to the sequence. The illustration of the Transformer encoder was inspired by Vaswani et al. (2017).

论文 Figure 1，左边是整体流程，右边是编码器内部

标准 Transformer 的输入是一维的词元嵌入序列，而图像是二维的，所以全部工作就是把图像变成这样一个序列。

2.1 图像 → 图块序列

设输入图像 x 的形状是 $H \times W \times C$ （高、宽、通道数，RGB 时 $C=3$ ）。取一个图块边长 P （比如 16），把图像切成不重叠的 $P \times P$ 小方块，得到

- 图块数 $N = HW / P^2$ ，这就是送进 Transformer 的序列长度；
- 每个图块展平成一个长度为 $P^2 \cdot C$ 的向量，整批图块的形状是 $N \times (P^2 \cdot C)$ 。

例：224×224 的图、 $P=16 \rightarrow N = (224 \times 224) / (16 \times 16) = 196$ 个图块，每个展平后长度 $16 \times 16 \times 3 = 768$ 。

2.2 线性投影 → 图块嵌入

Transformer 各层用的隐藏维度是一个常数 D 。用一个可训练的线性投影 E （形状 $(P^2 \cdot C) \times D$ ）把每个展平的图块映射到 D 维。这一步的输出叫图块嵌入(patch embedding)。

2.3 分类词元 + 位置嵌入

- 仿照 BERT 的 [class] 词元，在序列最前面**额外拼一个可学习的向量**（论文记作 x_{class} ，即位置 0）。它在编码器最后一层的输出就作为整张图的**图像表示**，分类头接在它上面。
- 给序列里每个位置加上**位置嵌入(position embedding)**，因为注意力本身不区分顺序。这里用的是**标准的可学习 1D 位置嵌入**——作者试过 2D 感知的版本，没有明显收益（见 4.4）。

于是编码器输入 z_0 是一个长度 $N+1$ 、维度 D 的序列。

2.4 编码器

就是原版 Transformer 编码器， L 层，每层 = 多头自注意力(MSA) + MLP，两个子层都是 **先 LayerNorm、再算、再残差相加 (Pre-LN)**。MLP 是两层、中间用 GELU 激活。最后对位置 0 的输出做一次 LayerNorm 得到图像表示 y 。

2.5 分类头

- 预训练时：一个带**一层隐藏层**的 MLP；
- 微调时：换成**单个线性层**（零初始化，输出维度 = 下游任务类别数）。

2.6 归纳偏置：ViT 比 CNN 少了什么

这是全文的核心论点，值得单列：

CNN 的局部性、二维邻域结构、平移等变性是**每一层都有的**。ViT 里只有 MLP 层是局部且平移等变的，**自注意力层是全局的**。二维结构只在两个地方用到：切图块的时候，以及微调换分辨率时调整位置嵌入。除此之外，位置嵌入初始化时不含任何二维位置信息，**图块之间的所有空间关系都要从数据里学**。

2.7 混合架构(hybrid)

一个折中方案：不直接切原图，而是先用 CNN 提特征图，再对特征图切块（极端情况图块是 1×1 ，即直接把特征图的空间维展平），后面流程完全相同。

2.8 微调与更高分辨率

下游微调时常用比预训练**更高的分辨率**。做法是**保持图块大小 P 不变**，于是图块数 N 变多、序列变长——Transformer 本身能处理任意长度，但预训练学到的位置嵌入就对不上了。解决办法：按图块在原图中的位置对位置嵌入做**二维插值**。

注意：切图块 + 这个分辨率调整，是全模型里**仅有的两处人工注入二维先验**的地方。

3. 实验设置

三个预训练数据集（规模递增）

数据集	类别数	图像数
ImageNet (ILSVRC-2012)	1k	1.3M
ImageNet-21k	21k	14M
JFT (Google 内部)	18k	303M

下游迁移评测：ImageNet（原标签 + 清洗过的 ReaL 标签）、CIFAR-10/100、Oxford-IIIT Pets、Oxford Flowers-102，以及 **VTAB**（19 个任务、每个只给 1000 张训练样本，分 Natural / Specialized（医学与卫星图）/ Structured（需要几何理解，如定位）三组）。

模型变体（照搬 BERT 的配置，另加一个 Huge）

模型	层数 L	隐藏维度 D	MLP 维度	头数	参数量
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

记号 **ViT-L/16** = Large + 16×16 图块。注意序列长度与 P^2 成反比，所以**图块越小、模型越贵**（ViT-L/14 比 ViT-L/16 贵得多）。

基线：ResNet(BiT)、EfficientNet-L2(Noisy Student)——都是当时最强的卷积网络，内部结构不影响理解本文，只当作对照。

训练：预训练用 Adam ($\beta_1=0.9, \beta_2=0.999$)，批大小 4096，权重衰减 0.1，线性 warmup + 衰减，分辨率 224；微调用带动量的 SGD，批大小 512，分辨率一般 384。

两种评测口径：**微调准确率**（正常微调后测）和**少样本(few-shot)线性准确率**（冻结表示、解一个带正则的最小二乘回归，有闭式解，用来快速评估）。

4. 主要结果

4.1 和 SOTA 比 (Table 2)

	ViT-H/14 (JFT)	ViT-L/16 (JFT)	ViT-L/16 (I21k)	BiT-L (ResNet152x4)	Noisy Student (EffNet-L2)
ImageNet	88.55	87.76	85.30	87.54	88.4/88.5
ImageNet ReaL	90.72	90.54	88.62	90.54	90.55
CIFAR-100	94.55	93.90	93.25	93.51	—
VTAB (19 任务)	77.63	76.28	72.72	76.29	—
TPUv3-核·天	2.5k	0.68k	0.23k	9.9k	12.3k

要点：

- 同样在 JFT-300M 上预训练，较小的 ViT-L/16 就已在所有任务上超过 BiT-L，且算力少一个数量级；ViT-H/14 进一步提升，尤其在更难的 ImageNet、CIFAR-100、VTAB 上。
- 只用公开的 ImageNet-21k 预训练的 ViT-L/16 也很能打，且一台 8 核 TPUv3 跑约 30 天就能训出来——这条对没有 JFT 的人最有现实意义。
- 作者自己提醒：预训练效率不只取决于架构，也受训练日程、优化器、权重衰减等影响，所以又做了 4.3 的受控对比。
- VTAB 分组看，ViT-H/14 在 Natural 和 Structured 组领先，Specialized 组与 BiT 相当。

4.2 数据规模是决定性因素




Figure 3: Transfer to ImageNet. While large ViT models perform worse than BiT ResNets (shaded area) when pre-trained on small datasets, they shine when pre-trained on larger datasets. Similarly, larger ViT variants overtake smaller ones as the dataset grows.




Figure 4: Linear few-shot evaluation on ImageNet versus pre-training size. ResNets perform better with smaller pre-training datasets but plateau sooner than ViT, which performs better with larger pre-training. ViT-b is ViT-B with all hidden dimensions halved.

两组实验：

(a) 换预训练数据集 (Figure 3)：ImageNet → ImageNet-21k → JFT-300M。

- 只在 ImageNet 上预训练时，ViT-Large 反而不如 ViT-Base（即使加了正则化：权重衰减、dropout、标签平滑）；
- ImageNet-21k 上两者相当；
- 只有到 JFT-300M，大模型的优势才完全体现。
- 灰色区域是各尺寸 BiT 的范围：小数据上 CNN 赢，大数据上 ViT 反超。

(b) 固定 JFT、只改子集大小 (Figure 4)：9M / 30M / 90M / 完整 300M，不额外调正则化、超参全一致，为的是看模型的内在性质而非正则化的效果；用少样本线性准确率评测以省算力。

- ViT 在小数据上比同等算力的 ResNet 更容易过拟合：ViT-B/32 在 9M 子集上明显差于 ResNet50，但在 90M 以上反超；ResNet152x2 与 ViT-L/16 同理。
- 结论：卷积的归纳偏置在小数据上 useful；数据一大，直接从数据里学这些模式就够了，甚至更好。

4.3 算力 vs 性能（受控的规模研究）




Figure 5: Performance versus pre-training compute for different architectures: Vision Transformers, ResNets, and hybrids. Vision Transformers generally outperform ResNets with the same computational budget. Hybrids improve upon pure Transformers for smaller model sizes, but the gap vanishes for larger models.

论文 Figure 5

在 JFT-300M 上固定数据、只比“预训练算力 → 迁移性能”，对象包括 7 个 ResNet、6 个 ViT、5 个混合模型。三个发现：

1. ViT 全面压过 ResNet 的性能/算力曲线，达到同样性能约省 2~4 倍算力（5 个数据集平均）。
2. 混合模型在小算力下略优于纯 ViT，但模型一大差距就消失——有点反直觉，本以为卷积的局部特征处理在任何尺寸都该有帮助。
3. 在尝试过的范围内 ViT 还没有饱和，值得继续扩大规模。

4.4 ViT 内部学到了什么




Figure 7: **Left:** Filters of the initial linear embedding of RGB values of ViT-L/32. **Center:** Similarity of position embeddings of ViT-L/32. Tiles show the cosine similarity between the position embedding of the patch with the indicated row and column and the position embeddings of all other patches. **Right:** Size of attended area by head and network depth. Each dot shows the mean attention distance across images for one of 16 heads at one layer. See Appendix D.7 for details.

论文 Figure 7

- **左：图块嵌入的线性投影 E。**取其前几十个主成分可视化，看起来像一组合理的基函数，用来表示图块内部的精细结构。
- **中：位置嵌入之间的余弦相似度。**模型自己学出了二维拓扑：位置越近的图块，位置嵌入越相似，并且出现明显的行/列结构（同行同列相似），网格大时还有正弦式结构。这解释了为什么手工设计的 2D 位置嵌入没带来提升——1D 版本自己就学会了。
- **右：注意力距离。**定义为按注意力权重加权的“查询位置与被关注位置的平均像素距离”，作用类似 CNN 里的感受野大小。现象是：**最低层就有一部分注意力头看遍全图**（说明全局建模能力确实被用上了），另一些头在低层始终只看很小范围；**随深度增加，所有头的注意力距离都变大**。在混合模型里，这种“低层局部头”少得多——说明纯 ViT 的局部头起的作用类似 CNN 的早期卷积层。
- 整体上，模型关注的是与分类语义相关的图像区域（Figure 6 的注意力图）。

4.5 自监督的初步尝试

模仿 BERT 的掩码语言建模，做**掩码图块预测(masked patch prediction)**：破坏 50% 的图块嵌入（80% 换成可学习的 [mask]、10% 换成随机的其他图块嵌入、10% 保持不变），去预测被破坏图块的 3-bit 平均颜色（共 512 种）。

结果：ViT-B/16 达到 ImageNet **79.9%**，比从零训练高 2 个点，但仍落后大规模监督预训练 4 个点。对比学习留给未来工作。

5. 附录里几个值得记住的结论

- **Transformer 形状消融(D.2)**: 加深度收益最大 (16 层后已见递减, 到 64 层仍可见提升), 加宽度收益最小, 减小图块大小 (=拉长序列) 在不增加参数的情况下稳定涨点。→ **算力比参数量更能预测性能; 要扩就优先扩深度**; 整体按比例放大所有维度最稳。
- **分类词元 vs 全局平均池化(D.3)**: 一开始 GAP 表现极差, 但查下来既不是因为多了那个词元、也不是 GAP 本身的问题, 而是**两者需要的学习率不同**; 调对学习率后两者效果相当。
- **位置嵌入消融(D.4)**: **有 vs 无**差距很大 (0.614 → 0.642, ImageNet 5-shot 线性); 但 1D / 2D / 相对位置嵌入之间几乎没差别。作者的猜测: 编码器处理的是图块级输入 (14×14) 而非像素级 (224×224), 空间分辨率低, 学空间关系对哪种编码方式都同样容易。
- **ResNet 用 Adam 而非 SGD(D.1)**: 在本文的 JFT 预训练设定下, Adam 预训练的 ResNet 迁移效果平均优于 SGD——所以基线不是被故意训弱的。
- **实测速度(D.5)**: ViT 的推理速度与同量级 ResNet 相当, 而单核能塞下的批大小明显更大, 即显存效率更高。
- **ObjectNet(D.9)**: ViT-H/14 取得 82.1% top-5 / 61.7% top-1。

6. 作者自述的局限与后续方向

1. 只做了图像分类, 检测、分割等任务尚待验证 (作者指向 DETR 的结果认为有希望)。
2. 自监督预训练与大规模监督预训练之间**仍有明显差距**。
3. 继续扩大规模很可能还能涨。

7. 我的归纳: 这篇论文真正的贡献

不是“发明了一个新架构”——把图像切块喂 Transformer 的想法此前已有 (最接近的是 Cordonnier et al. 2020, 切 2×2 图块 + 全局自注意力, 但因图块太小只能处理低分辨率图)。

而是用实验建立了一个到今天仍在支配大模型研发的判断:

当数据规模足够大时, 人工注入的归纳偏置会从“帮助”变成“限制”; 去掉它、换成一个可扩展规模、在加速器上跑得快的通用架构, 收益更大。

外加一个工程上的副产品: NLP 那套成熟的 Transformer 实现和扩展经验, 可以近乎零改动地搬到视觉上——这正是作者刻意“尽可能不改原版 Transformer”的原因。